

NIPT 的时点选择与胎儿的异常判定

摘要

NIPT 通过检测孕妇外周血中胎儿游离 DNA 筛查染色体异常，准确性取决于胎儿 DNA 浓度是否达标。男胎 Y 染色体浓度随孕周上升但受 BMI 稀释，检测过早浓度不足、过晚则错过治疗窗口。本文针对不同 BMI 孕妇的最佳 NIPT 时点选择及女胎异常判定，建立四个递进模型。

针对问题一，首先，267 名孕妇 1082 条纵向数据的组内相关系数达 0.60，普通回归会低估标准误。其次，孕周与浓度存在非线性关系，线性假设拟合不足。然后，建立**广义加性混合模型 (GAMM)**，用 B 样条拟合孕周和 BMI 的非线性效应，随机截距与随机斜率刻画个体差异。最后，GAMM 的 AIC 为 **-5240.80**，似然比检验卡方值 **76.76**，非线性改进极其显著，BMI 对浓度有负向抑制作用。

针对问题二，首先，不同 BMI 孕妇浓度达到 4% 的时间差异明显，统一时点无法兼顾准确性与时效性。其次，构造双风险函数将延迟风险与检测不准确风险加权为可优化目标。然后，以 BIC 准则搜索最优 BMI 分组，得到断点 30 和 36，分为三组。最后，各组最佳 NIPT 时点为 **11.7 周、11.8 周、13.5 周**，高 BMI 组对误差最敏感，阈值偏移 2% 可使时点推迟约 8 周。

在问题二基础上，针对问题三，首先，BMI 与体重的 VIF 高达 351，直接纳入导致共线性。其次，残差分解将 VIF 降至 **1.01**。然后，扩展 GAMM 纳入年龄和体重残差，500 次 Monte Carlo 模拟量化误差传播。最后，年龄和体重残差均不显著，BMI 单因素已足够，高 BMI 组 95% 置信区间宽达 [11.0, 24.6] 周。

针对问题四，首先，女胎不携带 Y 染色体，数据中全部标记为健康，缺乏正样本。其次，选择无监督的**多元马氏距离异常检测**，利用 6 维特征协方差结构识别异常。最后，马氏距离法 AUC 为 **0.574**，优于 Z 值阈值法 0.492，13 号染色体异常最易检出，21 号检出困难。

创新点 (1) GAMM 捕捉孕周非线性效应，似然比检验量化改进幅度；(2) 双风险函数将 NIPT 时点选择转化为可优化决策问题；(3) 残差分解消除共线性 (VIF 从 351 降至 1.01)，Monte Carlo 模拟量化高 BMI 组时点不确定性。

关键词： NIPT 检测；广义加性混合模型 (GAMM)；BMI 分段优化；Monte Carlo 误差传播；马氏距离异常检测

一、问题重述

无创产前检测 (NIPT) 通过分析孕妇外周血中的游离胎儿 DNA 片段来评估胎儿的遗传状态。当胎儿为男性时, 母体血液中可检测到 Y 染色体特异性序列, 其浓度随孕周增长而升高。孕妇的体质量指数 (BMI) 越高, 母体自身游离 DNA 对胎儿 DNA 的稀释效应越强, 导致检测信噪比下降。

本文围绕以下四个问题展开建模。问题一要求建立 Y 染色体浓度关于孕周与 BMI 的定量模型, 刻画浓度随孕周的非线性增长趋势及 BMI 的稀释作用。问题二要求按 BMI 水平对孕妇分组, 在每组内确定 NIPT 的最优检测时点, 使检测的准确性与时效性达到综合最优。问题三将模型扩展至包含年龄、体重、身高等多因素, 评估不同体征组合下的检测达标率, 并分析测量误差在模型中的传播效应。问题四针对女性胎儿 (无 Y 染色体信号), 利用 Z 值等指标建立染色体非整倍体异常的判别模型。

二、问题分析

2.1 问题一分析

附件数据包含 267 名孕妇共 1082 次纵向检测记录, 每名孕妇平均约 4 次观测, 构成非平衡面板结构。同一孕妇的重复测量之间存在显著相关性 (组内相关系数 ICC 约 0.60), 若使用普通最小二乘回归将低估标准误并产生虚假显著性。Y 染色体浓度随孕周的变化呈非线性特征, BMI 的稀释效应可能与孕周存在交互作用。因此需要采用能同时处理个体聚类效应和非线性趋势的纵向数据模型。

2.2 问题二分析

检测时点的选择面临双重约束。过早检测时胎儿 DNA 浓度偏低, 检测灵敏度不足; 过晚检测则压缩了后续临床干预的时间窗口。不同 BMI 组别的孕妇 DNA 浓度曲线形态和达标时间存在系统性差异, 需要在分组基础上构建同时反映准确性风险和延迟风险的目标函数, 通过优化求解各组的最优时点。

2.3 问题三分析

引入年龄、体重、身高等多因素后, 模型维度增加, 变量间可能存在共线性 (如体重与 BMI 高度相关)。达标率的评估需要在多维体征空间上进行条件概率计算。测量误差从自变量端传入模型后, 会通过非线性映射放大或缩小, 需利用 Delta 方法或蒙特卡罗模拟量化其对预测结果的影响。

2.4 问题四分析

女性胎儿缺乏 Y 染色体标记，无法直接复用前三问的浓度模型。染色体非整倍体的检测依赖对全基因组测序覆盖度的统计比较，Z 值衡量目标染色体读数相对参考分布的偏离程度。正常与异常样本的 Z 值分布存在重叠区域，单一阈值难以兼顾灵敏度与特异度，需要结合多个指标构建综合判别规则，并通过 ROC 分析评价分类性能。

三、 模型假设

- 1. 同一孕妇不同时间点的检测样本彼此独立（给定个体随机效应后）。
- 2. 孕妇个体差异可用随机截距和随机斜率充分刻画。
- 3. Y 染色体浓度的测量误差服从零均值正态分布。
- 4. 孕妇 BMI 在整个孕期检测窗口内近似不变。
- 5. 胎儿 DNA 释放速率与孕妇体征之间不存在未观测的混杂因素。
- 6. 染色体非整倍体异常的表现独立于检测时间点。

四、 符号说明

符号	说明	单位
y_{ij}	第 i 名孕妇第 j 次检测的 Y 染色体浓度	比例值
t_{ij}	第 i 名孕妇第 j 次检测的孕周	周
BMI_i	第 i 名孕妇的体质量指数	kg/m ²
b_{0i}, b_{1i}	第 i 名孕妇的随机截距与随机斜率	—
$s(\cdot)$	B 样条基函数	—
$R(t)$	NIPT 检测总风险函数	—
$R_{\text{delay}}(t)$	延迟风险分量	—
$R_{\text{inacc}}(t)$	不准确风险分量	—
T^*	最优 NIPT 检测时点	周
$P(y \geq c \mid t, g)$	BMI 组 g 在孕周 t 的达标比例	—
$d_M(\mathbf{x})$	马氏距离	—
σ_ε	残差标准差	—
N	样本量	—

五、问题一的建立与求解

本题需要从 267 名孕妇共 1082 条纵向观测数据中，建立 Y 染色体浓度关于孕周和 BMI 的定量模型。每名孕妇平均包含约 4 个时间点的重复测量，因此需要考虑个体内相关性对参数估计和推断的影响。

5.1 混合模型框架的选择依据

为评估个体层面聚类效应的强度，本文首先计算组内相关系数 (ICC)。以 σ_b^2 表示个体间方差、 σ_ε^2 表示残差方差，ICC 定义为

$$\text{ICC} = \frac{\sigma_b^2}{\sigma_b^2 + \sigma_\varepsilon^2} \quad (1)$$

计算结果为 $\text{ICC} = 0.60$ ，表明 Y 染色体浓度总变异的 60% 来源于个体间差异。若采用合并 OLS 回归忽略这一聚类结构，标准误将被系统性低估，进而导致假阳性膨胀。因此，本文采用混合模型框架，通过随机效应显式建模个体异质性，保证纵向重复测量下统计推断的有效性。

5.2 广义加性混合模型的建立

探索性分析表明，Y 染色体浓度随孕周的变化呈现明显的非线性趋势，线性假设无法充分拟合实际数据模式。为此，本文建立**广义加性混合模型 (GAMM，记为 M1)**作为主模型，同时建立**线性混合效应模型 (LME，记为 M2)**作为基准，通过嵌套比较评估非线性成分贡献。

GAMM 模型 (M1) 的具体形式为

$$y_{ij} = \beta_0 + s_1(t_{ij}) + s_2(\text{BMI}_i) + b_{0i} + b_{1i} t_{ij} + \varepsilon_{ij} \quad (2)$$

其中 y_{ij} 为第 i 名孕妇在第 j 次观测时的 Y 染色体浓度， t_{ij} 为对应孕周。各成分含义如下。

- $s_1(\cdot)$ 为孕周的非线性平滑函数，采用 B 样条基函数，自由度 $\text{df} = 4$ ；
- $s_2(\cdot)$ 为 BMI 的非线性平滑函数，采用 B 样条基函数，自由度 $\text{df} = 3$ ；
- $b_{0i} \sim N(0, \sigma_{b_0}^2)$ 为随机截距，刻画个体基线浓度差异；
- $b_{1i} \sim N(0, \sigma_{b_1}^2)$ 为孕周的随机斜率，刻画个体浓度增长速率差异；
- $\varepsilon_{ij} \sim N(0, \sigma_\varepsilon^2)$ 为观测误差。

LME 基准模型 (M2) 将两个平滑函数替换为线性项

$$y_{ij} = \beta_0 + \beta_1 t_{ij} + \beta_2 \text{BMI}_i + b_{0i} + b_{1i} t_{ij} + \varepsilon_{ij} \quad (3)$$

M2 与 M1 共享相同的随机效应结构，二者构成嵌套关系，可通过似然比检验直接比较。

5.2.1 模型求解步骤

模型估计按以下步骤执行。

Step 1（数据预处理） 对 267 名孕妇的 1082 条观测记录进行缺失值检查与异常值筛查，确认数据完整性后按孕妇编号排列，以适配混合模型的分组结构。

Step 2（参数估计） 采用限制最大似然法（REML）估计方差成分，固定效应参数通过 L-BFGS 优化器求解。REML 相比 ML 在方差分量估计上具有无偏性，适合样本量有限的纵向数据。

Step 3（模型比较） 对 M1 和 M2 分别以 ML 重新拟合（保证似然比检验的有效性），计算似然比统计量 $\Lambda = 2(\ell_{M1} - \ell_{M2})$ ，在 χ^2 分布下检验非线性成分的显著性。

Step 4（残差诊断） 对最优模型的残差进行正态性检验（Shapiro-Wilk）和分布形态分析（偏度、峰度），验证模型假设的合理性。

5.3 模型求解结果

表 2 汇总了 M1（GAMM）与 M2（LME）在主要评价指标上的对比结果。

表 2 GAMM (M1) 与 LME (M2) 模型评价指标对比

模型	AIC	BIC	RMSE	对数似然
M1 (GAMM)	-5240.80	-5180.96	0.0101	2632.40
M2 (LME)	-5174.04	-5139.13	0.0111	—

似然比检验结果为 $\chi^2 = 76.76$ ($df = 5$, $p < 10^{-15}$)，M1 在统计意义上显著优于 M2。M1 的 AIC 较 M2 低 66.76，BIC 低 41.83，RMSE 降低约 9%，三项指标一致支持非线性模型的优越性。

M1 的固定效应估计如下。截距 $\hat{\beta}_0 = 0.0107$ ；孕周 B 样条基系数依次为 0.0153、0.0173、0.0434、0.1238，呈递增趋势，反映 Y 染色体浓度随孕周的加速上升特征；BMI 的 B 样条基系数为 0.1023、0.0127、0.0150。随机效应方面，随机截距方差 $\hat{\sigma}_{b0}^2 = 0.001886$ ，随机斜率方差 $\hat{\sigma}_{b1}^2 = 0.000008$ ，个体基线差异远大于斜率差异，与 ICC=0.60 的结果相呼应。

残差诊断显示偏度为 0.125，峰度为 4.15，Shapiro-Wilk 统计量 $W = 0.943$ 。残差分布接近对称，峰度略高于正态分布的理论值 3，存在轻微的尖峰特征，但在大样本条件下 ($n = 1082$) 对 REML 估计的稳健性影响有限。

图 1 展示了 M1 与 M2 在孕周和 BMI 两个维度上的偏效应对比。GAMM 的孕周偏效应曲线呈现明显的非线性上升形态，尤其在孕晚期阶段斜率显著增大，而 LME 仅

能以固定斜率的直线近似这一趋势，拟合精度受限。




图 1 M1 (GAMM) 与 M2 (LME) 偏效应对比

图 2 进一步给出 GAMM 模型中孕周偏效应的单独可视化及其 95% 置信带。B 样条基系数从早期的 0.0153 递增至 0.1238，表明 Y 染色体浓度在孕早期增长平缓，进入中晚期后加速上升。这一非线性特征是 GAMM 相对于 LME 取得统计改进的核心来源。




图 2 GAMM 模型孕周偏效应曲线

5.4 结果分析

GAMM 的求解结果揭示了三个关键规律。

(1) 孕周对 Y 染色体浓度具有强非线性正向效应。样条基系数序列 $0.0153 \rightarrow 0.0173 \rightarrow 0.0434 \rightarrow 0.1238$ 表明浓度增速并非恒定，而是随孕周推进逐步加快。似然比检验 ($\chi^2 = 76.76, p < 10^{-15}$) 从统计角度证实了这一非线性成分不可省略。

(2) BMI 对 Y 染色体浓度存在负向调节作用。BMI 样条基的首项系数 0.1023 后迅速回落至 0.0127 和 0.0150，提示高 BMI 孕妇体内母体血浆体积增大，对胎儿游离

DNA 产生稀释效应，导致检测浓度偏低。

(3) 个体异质性显著。ICC=0.60 意味着超过半数的浓度变异归因于个体间差异，随机截距方差 $\hat{\sigma}_{b_0}^2 = 0.0019$ 远大于随机斜率方差 $\hat{\sigma}_{b_1}^2 = 0.000008$ ，说明不同孕妇的基线浓度水平差异是个体异质性的主要表现形式。

从 NIPT 临床实践角度看，孕周效应的非线性特征意味着采用固定检测窗口对所有孕妇施行统一采样策略并非最优方案。在孕早期浓度增速较慢的阶段，过早采样可能因浓度不足而增加检测失败风险；在孕中晚期浓度快速攀升的阶段，检测灵敏度则相对充裕。BMI 的稀释效应进一步加剧了这一问题，高 BMI 孕妇在相同孕周下的浓度水平系统性偏低，需要推迟采样以补偿浓度劣势。这两项发现共同指向一个自然的后续问题，即如何根据孕妇的 BMI 水平制定分组化的最优检测时点，这正是问题二所要回答的核心内容。

六、 问题二的建立与求解

6.1 数据驱动的 BMI 分组

6.1.1 选择依据

不同 BMI 水平的孕妇，胎儿游离 DNA 浓度的增长速率存在显著差异，导致 NIPT 检测达标时间随 BMI 变化。若对全部孕妇采用统一检测时点，高 BMI 群体将面临较高的误检风险。因此，需要按 BMI 水平将孕妇划分为若干组，在每组内分别确定最优检测时点。传统做法依赖临床经验设定固定分界值，缺乏统计支撑。本文采用数据驱动策略，以组内达标时间方差最小化为目标，自动搜索最优分组断点。

6.1.2 总述

267 名孕妇中，260 名在观测期内 Y 染色体浓度首次达到检测阈值 $c = 0.04$ （即 4%），据此定义经验达标时间 T^* 。对 T^* 关于 BMI 建立 **Huber 稳健回归**模型，在候选断点空间中穷举搜索，以 BIC 准则同时确定分组数目与断点位置。

6.1.3 求解步骤

Step 1 经验达标时间提取。对每位孕妇的纵向浓度序列，取 Y 染色体浓度首次满足 $\hat{y}(t) \geq 0.04$ 的孕周作为该患者的经验达标时间 T^* 。267 名孕妇中有 260 名在观测窗口内达标，后续分析基于这 260 条记录。

Step 2 稳健回归建模。以 BMI 为自变量， T^* 为因变量，拟合二次稳健回归模型

$$T^* = \beta_0 + \beta_1 \cdot \text{BMI} + \beta_2 \cdot \text{BMI}^2, \quad (4)$$

采用 Huber M-估计量以降低离群点的影响。图 3 展示了 T^* 随 BMI 的变化趋势与拟合曲线。

Step 3 穷举断点搜索。在 $BMI \in [24, 44]$ 范围内以步长 1.0 枚举所有候选断点组合，约束每组 BMI 宽度不少于 3.0 个单位、每组样本量不少于 5 人。对每种分组方案，计算组内 T^* 的加权方差，并以 BIC 准则评价模型复杂度与拟合优度的平衡。

Step 4 最优分组确定。BIC 最小方案对应两个断点 $BMI = 30$ 与 $BMI = 36$ ，将孕妇分为 3 组。与临床经验 5 组方案（断点 20/28/32/36/40）相比，数据驱动 3 组方案的 BIC 更优，表明额外分组并未带来实质性的组内方差下降。




图 3 经验达标时间 T^* 与 BMI 的关系及稳健回归拟合曲线，竖线标注最优断点

6.2 风险函数的建立

6.2.1 选择依据

NIPT 检测时点的选择涉及两类相互竞争的风险。检测过早，胎儿游离 DNA 浓度尚未充分积累，检测准确性不足；检测过晚，则延误临床干预窗口。需要构造统一的风险函数，将两类风险量化并加权求和，为后续最优时点求解提供目标函数。

6.2.2 模型构建

总风险函数定义为

$$R(t, BMI) = w_d \cdot R_{\text{delay}}(t) + w_a \cdot R_{\text{inacc}}(t, BMI), \quad (5)$$

其中 $w_d = 0.4$, $w_a = 0.6$ ，反映临床实践中检测准确性的优先级高于时效性。

延迟风险采用 Sigmoid 函数建模

$$R_{\text{delay}}(t) = \frac{1}{1 + e^{-0.5(t-18)}}, \quad (6)$$

该函数在孕 18 周附近快速上升，刻画了超过常规检测窗口后临床干预机会急剧减少的特征。

不准确风险基于 GAMM 预测浓度 $\hat{y}(t, \text{BMI})$ 与残差标准差 $\sigma_\varepsilon = 0.0101$ ，通过标准正态累积分布函数 Φ 计算浓度低于检测阈值 $c = 0.04$ 的概率

$$R_{\text{inacc}}(t, \text{BMI}) = \Phi\left(\frac{c - \hat{y}(t, \text{BMI})}{\sigma_\varepsilon}\right). \quad (7)$$

当预测浓度远高于阈值时， R_{inacc} 趋近于 0；当预测浓度接近或低于阈值时， R_{inacc} 迅速增大。图 4 展示了两类风险分量及总风险随孕周的变化。




图 4 各 BMI 组的风险函数分析，延迟风险、不准确风险及总风险随孕周的变化

6.3 最优检测时点求解

对第 g 组，取该组 BMI 均值 $\overline{\text{BMI}}_g$ 代入风险函数，在孕周区间 $[10, 25]$ 上求解单变量有界优化问题

$$T_g^* = \arg \min_{t \in [10, 25]} R(t, \overline{\text{BMI}}_g), \quad (8)$$

使用 Brent 方法进行精确求解。三组的最优检测时点及对应风险值列于表 3。

表 3 各 BMI 组最优检测时点与风险值

组别	BMI 范围	样本量	BMI 均值	最优孕周	最小风险
G1	[20.7, 30.0)	76	28.9	11.72	0.0208
G2	[30.0, 36.0)	171	32.3	11.80	0.0218
G3	[36.0, 46.9)	20	38.4	13.49	0.0675

G1 与 G2 组的最优时点十分接近（约 11.7~11.8 周），最小风险均低于 0.025，表明中低 BMI 孕妇在孕 12 周前即可获得高置信度的检测结果。G3 组（BMI ≥ 36 ）的最优时点推迟至 13.49 周，最小风险升高至 0.0675，约为前两组的 3 倍。这一差异源于高 BMI 孕妇的母体游离 DNA 对胎儿 DNA 的强稀释效应，使浓度达标时间整体后移。图 5 展示了三组孕妇的浓度预测曲线，高 BMI 组浓度增长更缓慢。




图 5 各 BMI 组的浓度预测曲线

6.4 检测误差敏感性分析

为评估当检测阈值发生偏移或残差方差增大时，各组最优时点与最小风险的稳定性，设置两类扰动实验。

(1) 阈值偏移。将检测阈值 c 分别上调 0.5%、1%、2%（即 $c = 0.045$ 、 0.05 、 0.06 ），模拟系统性测量偏差对结果的影响。

(2) 噪声膨胀。将残差标准差 σ_ε 分别放大至 1.5 倍、2 倍、3 倍（即 $\sigma_\varepsilon = 0.0152$ 、 0.0202 、 0.0303 ），模拟随机误差增大的场景。




图 6 检测误差敏感性分析，阈值偏移与噪声膨胀对各组风险的影响

图 6 显示，G1 和 G2 组在所有扰动条件下，最优时点偏移不超过 0.5 周，最小风险增幅有限，表现出良好的鲁棒性。G3 组对两类扰动均表现出显著敏感性，当噪声放大至 3 倍时，最小风险超过 0.15，最优时点进一步推迟。这一结果与高 BMI 组本身信噪比偏低的物理机制一致。

七、问题三的建立与求解

问题一和问题二的模型仅纳入孕周与 BMI 两个因素。问题三进一步考察年龄和体重对 Y 染色体浓度预测的增量贡献，并在多因素框架下重新优化分组检测时点。由于体重、身高与 BMI 之间存在严重的多重共线性，直接纳入将导致参数估计不稳定，需要先进行变量解耦。

7.1 多重共线性诊断与残差分解

7.1.1 共线性诊断

将体重、身高、BMI 和年龄同时纳入线性模型，计算各变量的方差膨胀因子 (VIF)。VIF 衡量自变量间线性相关对回归系数方差的放大倍数，定义为

$$VIF_k = \frac{1}{1 - R_k^2} \quad (9)$$

其中 R_k^2 为第 k 个自变量对其余自变量回归的决定系数。原始变量的 VIF 结果如表 4 所示。

表 4 残差分解前各变量的 VIF

变量	BMI	身高	体重	年龄
VIF	218.6	106.9	351.3	1.01

BMI、身高和体重三者的 VIF 均远超 10，直接建模将使系数估计高度不稳定。

7.1.2 残差分解策略

为保留体重中独立于 BMI 和身高的信息，本文采用残差分解法。将体重对 BMI 和身高进行辅助回归

$$\text{weight}_i = \gamma_0 + \gamma_1 \cdot \text{BMI}_i + \gamma_2 \cdot \text{height}_i + e_i \quad (10)$$

残差 e_i 即为体重中无法被 BMI 和身高线性解释的部分，记为 weight_resid_i 。以 BMI、年龄和 weight_resid 替换原始变量后，重新计算 VIF，结果如表 5 所示。

表 5 残差分解后各变量的 VIF

变量	BMI	年龄	weight_resid
VIF	1.00	1.01	1.01

分解后所有 VIF 均接近 1，共线性问题完全消除。图 7 直观展示了分解前后 VIF 的对比。




图 7 残差分解前后各变量 VIF 对比

7.2 多因素 GAMM 模型

在问题一 GAMM 的基础上，将年龄和体重残差作为线性固定效应纳入，建立**多因素广义加性混合模型（Multi-factor GAMM，记为 M1）**

$$y_{ij} = \beta_0 + s_1(t_{ij}) + s_2(\text{BMI}_i) + \beta_3 \cdot \text{age}_i + \beta_4 \cdot \text{weight_resid}_i + b_{0i} + b_{1i} t_{ij} + \varepsilon_{ij} \quad (11)$$

模型 M1 的 AIC=-5214.43。M1 中新增线性项的系数估计如表 6 所示。

表 6 M1 模型中年龄与体重残差的系数估计

变量	系数	标准误	<i>p</i> 值
age	-0.000491	0.000482	0.309
weight_resid	-0.001020	0.002514	0.685

两个变量的 *p* 值均远大于 0.05，未达到统计显著性。BMI 的非线性样条效应在 M1 中仍为最主要的预测成分。这一结果表明，在已纳入 BMI 非线性效应的条件下，年龄和体重（扣除 BMI 和身高的线性贡献后）对 Y 染色体浓度不具有显著的额外预测能力。图 8 给出了多因素 GAMM 的残差诊断结果。




图 8 多因素 GAMM 残差诊断

7.3 达标比例与风险优化

问题二的最优时点仅基于群体预测均值确定，未考虑个体间预测分布的离散程度。为更全面地权衡检测时机，本文定义达标比例（compliance rate）为 BMI 分组 g 在孕周 t 时，预测 Y 染色体浓度不低于检测阈值 $c = 0.04$ 的个体占比

$$P(y \geq 0.04 \mid t, g) = \frac{1}{N_g} \sum_{i \in g} \mathbf{1}[\hat{y}_i(t) \geq 0.04] \quad (12)$$

同时定义延迟检测风险 $R_{\text{late}}(t)$ 为分段线性函数

$$R_{\text{late}}(t) = \begin{cases} 0, & t \leq 12 \\ \frac{0.5(t-12)}{20-12}, & 12 < t \leq 20 \\ 0.5 + \frac{0.5(t-20)}{25-20}, & 20 < t \leq 25 \end{cases} \quad (13)$$

综合两项指标，构建加权风险函数

$$R(t, g) = 0.3 \cdot R_{\text{late}}(t) + 0.7 \cdot (1 - P(y \geq 0.04 \mid t, g)) \quad (14)$$

将 267 名孕妇划分为 4 组，对每组在 $t \in [11, 25]$ 周的网格上逐点计算 $R(t, g)$ ，取最小值对应的孕周为最优检测时点。结果如表 7 所示。

表 7 各 BMI 组的最优检测时点与达标比例

BMI 分组	样本量	最优孕周	达标比例	最小风险值
[20, 32)	152	12.8	75.3%	0.187
[32, 36)	95	13.3	74.8%	0.200
[36, 40)	16	13.3	67.0%	0.256
[40, $+\infty$)	4	24.8	95.0%	0.329

前三组的最优时点集中在 12.8 至 13.3 周，与问题二的结论基本吻合。BMI $\geq$ 40 组的最优时点被推迟至 24.8 周，原因在于该组胎儿游离 DNA 浓度增长极为缓慢，在 12 至 20 周区间内达标比例始终偏低，风险函数直到接近观测窗口上限才取得最小值。各组达标比例随孕周的变化如图 9 所示。




图 9 各 BMI 组达标比例随孕周变化曲线

7.4 Monte Carlo 误差传播分析

上述最优时点的确定依赖于 GAMM 的点估计和固定的残差方差 σ_ε^2 。为量化测量噪声不确定性对结果的影响，本文采用 Monte Carlo 误差传播方法。在每次迭代中，从均匀分布 $U(0.5, 1.5)$ 中抽取缩放因子 λ ，将残差标准差设为 $\lambda\hat{\sigma}_\varepsilon$ ，重新执行达标比例模拟并搜索最优孕周。重复 500 次，收集每组最优时点的经验分布。结果如表 8 所示，各组时点的经验分布见图 10。

表 8 Monte Carlo 误差传播下各 BMI 组最优时点的分布统计

BMI 分组	均值 (周)	标准差 (周)	95% 置信区间
[20, 32)	13.02	0.64	[11.94, 14.34]
[32, 36)	13.17	0.81	[11.94, 15.00]
[36, 40)	14.47	3.04	[11.38, 23.64]
[40, +∞)	16.15	4.75	[11.00, 24.58]




图 10 Monte Carlo 模拟下各 BMI 组最优检测时点的经验分布

BMI 在 $[20, 32)$ 和 $[32, 36)$ 两组的最优时点分布集中, 标准差分别为 0.64 周和 0.81 周, 95% 置信区间宽度不超过 3.1 周, 表明这两组的时点推荐具有良好的稳健性。BMI 在 $[36, 40)$ 组的标准差增至 3.04 周, 置信区间跨度达 12.3 周, 推荐精度明显下降。BMI ≥ 40 组的置信区间从 11.0 周延伸至 24.6 周, 跨度达 13.6 周, 最优时点在测量噪声扰动下几乎不可确定。该组仅包含 4 名孕妇, 样本量的严重不足是导致估计不稳定的根本原因。

7.5 问题二与问题三差异分析

问题二采用单因素 3 组方案 (断点 BMI=30 和 36), 问题三扩展为多因素 4 组方案 (断点 BMI=32、36 和 40)。分组断点的偏移源于两方面原因。第一, 问题三的风险函数采用达标比例而非群体均值预测, 对个体间分布离散度更敏感。第二, 问题三引入更细的 BMI 分层以容纳极端高 BMI 组 (≥ 40), 该组虽仅 4 例但浓度特征与其余高 BMI 孕妇有明显差异。BMI ≥ 40 组 24.8 周的推荐时点统计不确定性极高, 不应作为临床决策的唯一依据。

八、 问题四的建立与求解

本题针对女性胎儿样本, 由于缺少 Y 染色体标记, 无法沿用前述基于 Y 染色体浓度的分析路径。需要利用 NIPT 检测的多维汇总统计量, 建立染色体非整倍体异常的检测模型。数据集包含 604 例女性胎儿样本, 其中正常 537 例、异常 67 例, 异常率约为 11.1%。

8.1 问题转化与特征选择

女性胎儿不携带 Y 染色体, 前三个问题的 Y 染色体浓度建模思路不再适用。问题四的核心任务转化为, 在多维 NIPT 汇总指标空间中将异常样本与正常样本区分开来。

经初步相关性分析与临床意义筛选, 确定以下 6 个核心特征构成输入空间。

- 13 号染色体 Z 值 (Z_{13})、18 号染色体 Z 值 (Z_{18})、21 号染色体 Z 值 (Z_{21})
- X 染色体 Z 值 (Z_X)

- 孕妇 BMI
- X 染色体浓度

8.2 多元马氏距离异常检测模型

本文建立**多元马氏距离异常检测模型**（记为 M1）作为主方法。以正常样本的多维分布为参照，计算每个待检样本偏离正常群体中心的马氏距离，距离越大则异常可能性越高。

设正常样本集为 $\{\mathbf{x}_k\}_{k=1}^{n_0}$ ，其中 $\mathbf{x}_k \in \mathbb{R}^6$ 为 6 维特征向量。首先估计正常群体的均值向量 $\boldsymbol{\mu}$ 和协方差矩阵 $\boldsymbol{\Sigma}$

$$\boldsymbol{\mu} = \frac{1}{n_0} \sum_{k=1}^{n_0} \mathbf{x}_k, \quad \boldsymbol{\Sigma} = \frac{1}{n_0 - 1} \sum_{k=1}^{n_0} (\mathbf{x}_k - \boldsymbol{\mu})(\mathbf{x}_k - \boldsymbol{\mu})^T \quad (15)$$

对任意待检样本 $\mathbf{x}$ ，其马氏距离定义为

$$d_M(\mathbf{x}) = \sqrt{(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu})} \quad (16)$$

分类规则为，若 $d_M(\mathbf{x}) \geq \tau$ ，则标记为异常，否则判定为正常。阈值 τ 取正常样本马氏距离分布的某一百分位数，通过遍历不同百分位（p50 至 p99）选取 F1 分数最优的切点。

8.3 基线方法

本文建立**多元 Z 值联合阈值规则**（记为 M2）作为基线方法。M2 不考虑特征间的相关结构，直接对三条常染色体的 Z 值取平方和

$$S = Z_{13}^2 + Z_{18}^2 + Z_{21}^2 \quad (17)$$

分类规则为，若 $S \geq \tau$ ，则标记为异常。阈值 τ 同样在正常样本 S 值分布的百分位区间内搜索确定。M2 与 M1 的本质区别在于，M2 将协方差矩阵退化为单位阵，仅利用各 Z 值的边际信息，忽略了特征间的联合分布结构。

8.4 求解结果

在经验协方差估计下，M1 在正常样本马氏距离第 85 百分位处取得最优 F1 分数，对应阈值 $\tau = 2.997$ 。表 9 列出该阈值下的混淆矩阵与主要评价指标。

表 9 M1（多元马氏距离异常检测）在最优阈值下的检测结果

阈值（百分位）	TP	FP	FN	TN	召回率	精确率
p85 ($\tau = 2.997$)	18	81	49	456	26.87%	18.18%

M1 的 F1 分数为 0.217，AUC-ROC 为 0.574，AUC-PR 为 0.163。M2 在正常样本 S 值第 50 百分位处取得最优性能，召回率为 47.8%，精确率为 10.6%，F1 分数为 0.174。AUC-ROC 仅为 0.492，接近随机分类水平。

表 10 汇总了两种方法在关键指标上的对比。

表 10 M1 与 M2 检测性能对比

模型	AUC-ROC	AUC-PR	F1	召回率	精确率
M1（马氏距离）	0.574	0.163	0.217	26.87%	18.18%
M2（Z 值平方和）	0.492	—	0.174	47.80%	10.60%

M1 的 AUC-ROC 较 M2 高出 0.082，在精确率-召回率权衡上也更优。M2 虽然召回率较高，但精确率仅为 10.6%，大量正常样本被误判为异常，实际可用性不足。图 11 对比了 M1 在不同配置下的 ROC 曲线，图 12 展示了正常与异常样本的马氏距离分布，图 13 给出了两类样本在各染色体 Z 值上的分布对比。




图 11 M1 在不同配置下的 ROC 曲线对比




图 12 正常样本与异常样本的马氏距离分布




图 13 正常与异常样本的 Z 值分布对比

8.5 结果分析

两种方法的 AUC-ROC 均处于 0.5 至 0.6 区间，整体检测能力有限。这一结果反映了问题本身的内在困难，异常样本与正常样本在 NIPT 汇总统计量空间中的特征分布高度重叠，多数染色体非整倍体异常仅引起 Z 值的微小偏移，难以在群体层面形成清晰的分离边界。

M1 相对于 M2 的优势来源于马氏距离对特征间相关结构的利用。当多个 Z 值同时出现轻微偏移时，马氏距离能够识别这种联合偏离模式，而 M2 的平方和指标对各维度等权处理，丢失了协方差信息。

从临床应用角度评估，M1 提供了优于随机分类的筛查能力，可作为初步筛选工具缩小需要进一步确认的样本范围。在实际产前诊断流程中，NIPT 结果呈阳性的孕妇仍需接受羊膜穿刺或绒毛膜绒毛取样等确证性检查。检测能力的根本瓶颈在于 NIPT 汇

总统计量对微小染色体剂量变化的灵敏度不足，提升检测精度需要引入更细粒度的测序特征或结合多平台数据。

九、模型检验与灵敏度分析

9.1 灵敏度分析

GAMM 中孕周样条自由度 df_t 和 BMI 样条自由度 df_x 的选择影响模型复杂度。以 AIC 为指标， $df_t = 4$ 、 $df_x = 3$ 为最优组合 (AIC=-5240.8)。自由度降至 3/2 时 AIC 恶化约 30 个单位，升至 5/4 仅改善 1.3 个单位，模型对自由度选择保持稳健。

问题 2 风险函数中延迟权重 w_d 从 0.2 变至 0.6 时，G1 和 G2 组最优时点仅偏移 0.6 周，G3 组（高 BMI）偏移达 4.1 周，反映该组延迟风险与浓度不足风险之间张力更大。

问题 4 马氏距离阈值从 p_{80} 到 p_{95} ，召回率从 34.3% 下降至 13.4%，F1 在 p_{85} 处取得峰值 **0.217**。AUC 恒为 0.574，不随阈值变化。

9.2 误差与稳定性分析

GAMM 残差偏度 0.125、峰度 4.15，基本对称但呈轻微尖峰。RMSE=0.0101，残差量级相对于 Y 浓度均值较小。问题 2 将噪声放大至 2 倍时 G1/G2 组偏移不足 0.7 周，G3 组偏移约 2 周。问题 3 蒙特卡洛 500 次模拟显示 G1 组标准差 0.64 周、G2 组 0.81 周，推荐时点可靠；G3 组 3.04 周、G4 组 4.75 周，后两组统计可靠性不足。

9.3 对比验证

GAMM 与 LME 的似然比检验 $\chi^2 = 76.76$ ($p < 1 \times 10^{-15}$)，AIC 差值 66.8，强烈拒绝线性假设。数据驱动 3 组方案 BIC 低于临床 5 组方案，且各组样本量更均衡。马氏距离方法 (AUC=0.574) 优于 Z 值阈值方法 (AUC=0.492)，后者判别方向存在偏差。

十、模型评价

10.1 模型优点

(1) GAMM 正确处理了纵向面板结构 (ICC=0.60)，B 样条捕捉非线性效应，似然比检验 ($\chi^2 = 76.76$, $p < 1 \times 10^{-15}$) 证实显著优于线性模型，AIC 改善 66.8 个单位。(2) 双风险函数将时点选择转化为决策优化问题，同时纳入延迟风险和浓度不足概率，为不同 BMI 组给出可量化的最优时点。(3) 残差分解有效解决 BMI 与体重的共线性 (VIF 从 351 降至 1.01)，保留全部体成分信息。(4) 蒙特卡洛误差传播为每组时点

提供置信区间，诚实暴露高 BMI 组的统计不确定性。(5) 马氏距离利用 6 维特征协方差结构，AUC=0.574 优于单变量 Z 值方法的 0.492。

10.2 模型不足

(1) 高 BMI 组样本有限 (BMI>36 仅 20 人, BMI>40 仅 4 例), 蒙特卡洛分析显示 G4 组置信区间跨度超过 13 周。(2) GAMM 残差峰度 4.15, Beta-GLMM 理论上更适配有界响应变量但因收敛困难未实现。(3) 问题 4 AUC 仅 0.574, 异常与正常特征分布高度重叠, 根本瓶颈在于 NIPT 汇总统计量对微小染色体剂量变化灵敏度不足。(4) 风险函数权重缺乏临床结局数据校准, 高 BMI 组对权重选择高度敏感。

十一、 模型改进与推广

(1) 将正态分布假设替换为 Beta-GLMM, 改善 Y 浓度有界连续变量的尾部预测精度。(2) 将问题 4 从单次截面分析扩展为纵向轨迹分析, 追踪 Z 值随孕周的变化模式作为判别特征。(3) 利用临床结局数据校准风险函数权重, 使推荐时点有据可依。(4) 采用贝叶斯层次模型对小样本子组实现部分池化, 缩小高 BMI 组的极宽置信区间。

推广方面, 风险函数优化框架适用于 PAPP-A、 β -hCG 等其他产前筛查标志物的时点选择; 残差分解技术可推广至药代动力学、营养流行病学等涉及人体测量学共线性的建模场景; 蒙特卡洛误差传播方法适用于多步模型预测链的不确定性量化。

十二、 AI 工具使用声明

本文在论文撰写过程中使用了 AI 辅助工具进行文字润色和排版优化。所有模型建立、数据分析、结果解读和核心结论均由参赛队员独立完成。

参考文献

- [1] Lo Y M D, Tein M S C, Lau T K, et al. Quantitative analysis of fetal DNA in maternal plasma and serum: implications for noninvasive prenatal diagnosis[J]. American Journal of Human Genetics, 1998, 62(4): 768–775.
- [2] Ashoor G, Syngelaki A, Poon L C Y, et al. Fetal fraction in maternal plasma cell-free DNA at 11–13 weeks’ gestation: relation to maternal and fetal characteristics[J]. Ultrasound in Obstetrics & Gynecology, 2013, 42(1): 14–18.
- [3] Wood S N. Generalized Additive Models: An Introduction with R[M]. 2nd ed. Boca Raton: CRC Press, 2017.
- [4] Pinheiro J C, Bates D M. Mixed-Effects Models in S and S-PLUS[M]. New York: Springer, 2000.
- [5] De Maesschalck R, Jouan-Rimbaud D, Massart D L. The Mahalanobis distance[J]. Chemometrics and Intelligent Laboratory Systems, 2000, 50(1): 1–18.
- [6] Rubinstein R Y, Kroese D P. Simulation and the Monte Carlo Method[M]. 3rd ed. Hoboken: Wiley, 2016.
- [7] Revello R, Sarno L, Ispas A, et al. Screening for trisomies by cell-free DNA testing of maternal blood: consequences of a failed result[J]. Fetal Diagnosis and Therapy, 2016, 40(2): 89–95.
- [8] Kinnings S L, Geis J A, Almasri E, et al. Factors affecting levels of circulating cell-free fetal DNA in maternal plasma and their implications for noninvasive prenatal testing[J]. Prenatal Diagnosis, 2015, 35(8): 816–822.
- [9] Hastie T, Tibshirani R, Friedman J. The Elements of Statistical Learning: Data Mining, Inference, and Prediction[M]. 2nd ed. New York: Springer, 2009.
- [10] Wang E, Batey A, Struble C, et al. Gestational age and maternal weight effects on fetal cell-free DNA in maternal plasma[J]. Prenatal Diagnosis, 2013, 33(7): 662–666.

A 支撑材料文件清单

文件名	说明
code/Q1/q1_main.py	问题一 GAMM 与 LME 建模主程序
code/Q1/q1_robustness.py	问题一鲁棒性分析（样条自由度、交叉验证）
code/Q2/q2_main.py	问题二 BMI 分组与最优 NIPT 时点优化主程序
code/Q2/q2_robustness.py	问题二鲁棒性分析（断点、权重、阈值敏感性）
code/Q3/q3_main.py	问题三多因素 GAMM 与 Monte Carlo 误差传播主程序
code/Q3/q3_robustness.py	问题三鲁棒性分析（MC 收敛、分解稳定性）
code/Q4/q4_main.py	问题四马氏距离异常检测主程序
code/Q4/q4_baseline.py	问题四 Z 值阈值基线方法
code/Q4/q4_robustness.py	问题四鲁棒性分析（特征子集、阈值、留一验证）
code/Q4/run_all.py	问题四 M1 与 M2 对比运行脚本
workspace/data_raw/附件.xlsx	原始数据（题目附件）

以上所有 Python 程序均可独立运行，随机种子统一设为 42，保证结果可复现。